Introduction à numpy & pandas

Pourquoi le python, pourquoi ces bibliothèques spécifiques?

Vincent Guigue – Formation Continue 2023

SCIENCES SORBONNE UNIVERSITÉ
ISIR INSTITUT DES SYSTÈMES INTELLIGENTS ET DE ROBOTIQUE
MLIA Machine Learning & Deep Learning for Information Access

Un historique mouvant

- Fortran (70-90)
- C, C++ (80-…)
- Matlab
- Python (2010, …)
  - Mais un python en évolution

Une **opportunité** incroyable pour les sciences des données !

- Outils matures & unifiés

De la programmation orientée *data*

SCIENCES SORBONNE UNIVERSITÉ

Numpy = un environnement à l'intérieur de python

1. **numpy:** prise en main des outils
   - Cas d'usage : classification bayesienne
   - descente de gradient

2. **pandas : lien avec les API**
   - Traitement des json
   - Manipulation des dates
   - Syntaxe orientée BD

python™ NumPy pandas

Passer à un nouveau langage

- Cout faible
  - une fois que vous avez compris la logique générale
- Cout non négligeable:
  - comprendre les forces et les faiblesses du langage
  - Adapter sa manière de programmer (e.g. calculer un décile)
- Environnement(s) de développement
  - Importances des IDE
    - Visual Studio Code, Spyder…
  - Et les nouveaux environnement en ligne
    - Jupyter

Pourquoi numpy

- Pour la richesse des opérateurs
  - Développés en C et rapides
- Pour les interfaces riches et efficaces
  - Matplotlib, pandas
  - Scikit-learn
- Pour la préparation que ça représente <=> pytorch, tensorflow

Le but du cours

- Comprendre la philosophie de l'outil
- Acquérir les bons reflexes
- Consolider vos acquis en python
- Introduire des données dans la programmation avec pandas

Au-delà du cours

- Premier classifieur
- Descente de gradient
- Analyse de séries temporelles

Le programme

- Lancement d'un notebook
- Vendredi = Tutos numpy: 1 à 6
  - Opt: classification bayesienne
- Samedi = Pandas + prise en main de l'évaluation
  - Opt: classification bayesienne / gradient

Note: les séries temporelles NE sont VRAIMENT PAS au programme !

https://github.com/vguigue/tuto_numpy

Que savoir faire en python?

- Déclarer des variables
- Utiliser des clauses et des boucles

```
i=0
if i<30:
        i = i + 10
        print("i est inferieur a trente")
else: # le else est toujours optionnel et sans clause
        print("i est superieur a trente")
```

- Déclarer des fonctions

```
def calc_affine(a,b,x):
        return a*x+b
```

Que savoir faire en numpy?

- Créer des matrices
- Faire des opérations sur les matrices
- Construire des algorithmes autour de ces matrices
- Afficher des courbes, des nuages de points…